

Data Science und Machine Learning

Einführung für Studierende der Betriebswirtschaftslehre und
Wirtschaftsinformatik



Dieter Greipl
Hochschule Landshut

Danke

Dieses Buch entstand im Sommersemester 2022. Vielen Dank an meine Studierenden für zahlreiche Hinweise.

Copyright

...

Contents

Willkommen	2
0.1 Vorbereitungen	2
1 Python - Quickstart	3
1.1 Colab-Notebooks	3
1.2 Hallo Welt	3
1.3 Variablen	3
1.4 Datentypen	3
1.5 Operatoren	4
1.6 Datentypen in der Übersicht	6
2 Daten	7
2.1 Elementare Datentypen	7
2.2 Der Iris-Datensatz	8
2.3 Datentypen	8
2.4 Skalenniveaus	8
Latex Part	14
3 Chapter	14
3.1 Latex Section (H2)	14

Willkommen

Dieses Skript entstand (und entsteht) aus meinen Lehrveranstaltungen rund um das Thema **Data Science & Machine Learning**. Die Inhalte richten sich an Studierende, die erste Schritte auf das KI-Spielfeld wagen und das Potential von datengetriebenen Lösungsverfahren verstehen wollen.

Insofern richtet sich die Darstellung an Studierende mit vertieftem Interesse an KI, die einen für Studierende angemessenes Vorwissen im Bereich Mathematik mitbringen. Vorkenntnisse im Bereich der Programmierung sind nicht nötig, aber natürlich hilfreich.

Ich habe mich bemüht, zahlreiche Übungsbeispiele und Youtube-Videos einzubauen. Viele Themen lassen sich so besser darstellen. Sofern es Medien im Netz gibt, die die Sachverhalte gut darstellen, werde ich entsprechenden Links einbauen. Der Autor muss ja nicht der Meinung sein, alles besser zu können. Gleichwohl darf dadurch der rote Faden nicht verloren gehen.

0.1 Vorbereitungen

Dieses Skript ist als Unterlage für zahlreichen praktische Übungen mit Python angelegt. Ich werde hierzu **Colab-Notebooks** verwenden. Sie brauchen hierzu ein **Google-Konto**.

Noch einige Hinweise an Studierende meiner Module:

- Die folgende Youtube-Playlist kann zur Vertiefung einzelner Stoffteile nutzen: Youtube Playlist
- Wenige Passagen in diesem Skript sind eventuell in englischer Sprache gehalten.
- Dieses Skript
 - befindet sich in Teilen im Aufbau, leichte Fehler sind also möglich (und wahrscheinlich - für Hinweise bin ich dankbar)
 - geht nach der Prüfung off-line

Chapter 1

Python - Quickstart

1.1 Colab-Notebooks

1.2 Hallo Welt

```
print("Hallo Welt")
```

Ausgabe:

```
#> Hallo Welt
```

1.3 Variablen

Variablen sind Platzhalter für Werte, wir sprechen vom *Wert einer Variable*. Im nachfolgendem Beispiel wird der Variable mit dem Namen `x` in Zeile 1 der Wert 1 zugewiesen. Variablen haben immer einen Namen. Einen Wert erhalten sie erst durch eine sog. Zuweisung (wie in Zeile 1). In Zeile 2 drucken wir den Wert aus. Führen Sie also folgende Python-Befehle aus:

```
x = 1  
print(x)
```

Die erstmalige Zuweisung eines Wertes an eine Variable heißt Initialisierung.

1.4 Datentypen

1.4.1 Datentyp “Zahlen”

Ganze Zahlen und rationale Zahlen

Zahlen sind recht einfach zu verstehen, wir haben ja oben schon einige Beispiele gesehen. Hier nochmal eine Zusammenfassung wichtiger Beispiele mit rationalen Zahlen:

```
a = 2
b = 1/3
c = 1.1
# Funktionen
d = a + b; print(d)
d = a - b; print(d)
d = a * b; print(d)
d = a / b; print(d)
```

1.4.2 Datentyp “Strings”

Zeichenketten sind ebenfalls recht einfach zu verstehen. Führen Sie folgendes Beispiel aus:

```
vorname = "Hans"
nachname = 'Huber'
name = vorname + ", " + nachname
print(name)
```

f-Strings

Statt eine zusammengesetzte Zeichenkette mit dem “+” - Operator aufzubauen, kann ein sogenannter f-String verwendet werden (siehe Zeile 3). f-Strings bringen für uns keine neue Funktion, machen aber die Verknüpfung von Strings einfacher.

```
vorname = "Hans"
nachname = 'Huber'
name = f"{vorname}, {nachname}"
print(name)
```

1.4.3 Datentyp “Boolean”

Es gibt in der Theorie unendlich viele Zahlen und Zeichenketten, aber nur zwei Wahrheitswerte: wahr oder falsch. In Python: `True` und `False`

```
z1 = False;
print (z1)
print( type(z1) );

z2 = 1 < 4;
print( z2 );
print( type(z2) );

print ("z1 and z2:", z1 and z2);
print ("z1 or z2:", z1 or z2);
```

1.5 Operatoren

Die Bildschirmabzüge dieses Kapitels sind der Webseite https://www.w3schools.com/python/python_operators.asp entnommen. Erarbeiten Sie sich die Operatoren selbst in kleinen Programmen, so wie wir das zu Zahlen bereits oben gemacht haben.

Operator	Name	Example
+	Addition	$x + y$
-	Subtraction	$x - y$
*	Multiplication	$x * y$
/	Division	x / y
%	Modulus	$x \% y$
**	Exponentiation	$x ** y$
//	Floor division	$x // y$

Figure 1.1: bild1

1.5.1 Arithmetische Operatoren

1.5.2 Vergleichsoperatoren

Operator	Name	Example
==	Equal	$x == y$
!=	Not equal	$x != y$
>	Greater than	$x > y$
<	Less than	$x < y$
>=	Greater than or equal to	$x >= y$
<=	Less than or equal to	$x <= y$

1.5.3 Logische Operatoren

Operator	Description	Example
and	Returns True if both statements are true	$x < 5$ and $x < 10$
or	Returns True if one of the statements is true	$x < 5$ or $x < 4$
not	Reverse the result, returns False if the result is true	not($x < 5$ and $x < 10$)

1.6 Datentypen in der Übersicht

Nachfolgendes Programmstück beschreibt exemplarisch die nun bekannten Datentypen. Mit `type()` kann man sich den Datentyp einer Variable ausgeben lassen (oft hilfreich!)

```
x = 1;
print( f"1 : {type(x)}")

x = 1.1;
print( f"1.1 : {type(x)}")

x = 4/2;
print( f"4/2 : {type(x)}")

x = 'String';
print( f"'String' : {type(x)}")

x = [1,2,4];
print( f"[1,2,3] : {type(x)}")

x = (1,2);
print( f"(1,2) : {type(x)}")

x = 1 < -3
print( f"False : {type(x)}")
```

1.6.1 Zusammenfassung

Eingebauter Datentyp	Kürzel	Beispiele
Text (Strings)	str	x = "Haw-Landshut"
Zahlen (Numerisch)	int, float	x = 1 oder x = 1.1
Listen (Arrays)	list	x = [1,2,3]
Tupel	tuple	x = (1,2)
Wahrheitswerte	bool	x = (1 < 3)

Chapter 2

Daten

2.1 Elementare Datentypen

Daten¹ sind Ergebnisse von Beobachtungen, Messungen oder Berechnungen, die in einer bestimmten Form notiert, also aufgeschrieben sind. Häufig sprechen wir auch von *Werten*, statt von Daten. Ein Wert kann zum Beispiel die Zahl 27 oder die Note “*sehr gut*” sein. Offensichtlich gehören beide Werte zu verschiedenen Typen von Werten, den sogenannten Datentypen. Wir beschäftigen uns mit den Datentypen *Zahlen*, *Text* und *Boolean*.

Zahlen Werte dieses Datentyps sind z.B. 1, -1 , 1.7 oder $1/3$. Wie sie wissen, lässt sich die Menge der Zahlen noch weiter einteilen in natürliche Zahlen und reelle Zahlen (und noch ein paar mehr, die aber vorerst nicht gebraucht werden. Wir verwenden die Symbole \mathbb{N} für die natürlichen Zahlen und \mathbb{R} für die reellen Zahlen.

Wir notieren Zahlen wie üblich und verwenden in der Dezimalnotation den Punkt als Trennsymbol.

Text Werte dieses Datentyps sind zum Beispiel “Baum”, “Hans Huber” oder “sehr gut”. Zeichenketten beginnen und enden mit einem Anführungszeichen. In der Regel macht uns diese Notationen keine Probleme - manchmal wird es trotzdem ungemütlich: Kann eine Zeichenkette ein Anführungszeichen enthalten? Gibt es einen Unterschied zwischen der Zahl 123 und der Zeichenkette “123”? Wir vertiefen das hier nicht, sondern gehen die Fragen an, sobald sie uns begegnen.

Logischer Datentyp (Boolean) Dieser Datentyp umfasst nur zwei Werte, die sogenannten Wahrheitswerte. Wir werden in diesem Text die Notation *True* und *False* verwenden.

Wir nennen diese Datentypen “elementar”, weil uns eine weitere Aufteilung nicht sinnvoll erscheint. Der Begriff “elementar” ist nicht ganz korrekt, weil z.B. die Zahl 123 ja eine Folge von Ziffern und die Zeichenkette “Baum” eine Folge von Buchstaben ist. Elementar wäre also eher der Datentyp *Ziffer* oder *Buchstabe*, als der Datentyp *Zahl* oder *Text*. Auch über diese begriffliche Ruppigkeit sehen wir zu Beginn hinweg. In der Programmierung werden sie aber eine Rolle spielen.

Stellen sie sich jeden Datentyp als Menge vor. Die Elemente der Menge sind die zulässigen Werte des Datentyps. Offensichtlich besitzt die Menge der Zahlen oder Texte unendlich viele Elemente, während der Logische Datentyp nur zwei Werte kennt.

¹ sing. Datum

2.2 Der Iris-Datensatz

Der Iris-Datensatz enthält Messungen von jeweils 50 Blüten zu drei verschiedenen Lilien-Arten (setosa, versicolor, virginica)




Figure 2.1: Download

Gemessen werden pro Blüte in cm

- die Länge und Breite des Kronblattes (Petalum, petal) sowie
- die Länge und Breite des Kelchblattes (Sepalum, sepal)

2.2.1 Datensatz

Folgender - in der Community wohlbekannter - Datensatz liegt uns vor (Sie finden die Daten hier).

2.3 Datentypen

2.3.1 Elementare Datentypen

Zahlen

Strings

Logische Werte

Elementare Datentypen in Python

2.3.2 Komplexe Datentypen

Datum

Uhrzeit

Bilder

Komplexe Datentypen in Python

2.4 Skalenniveaus

2.4.1 Überblick




Figure 2.2: image (190)

	A	B	C	D	E	F
1	sepal_len	sepal_wid	petal_len	petal_wid	class	
2	7,2	3,6	6,1	2,5	virginica	
3	5	3,6	1,4	0,2	setosa	
4	4,4	3	1,3	0,2	setosa	
5	4,7	3,2	1,6	0,2	setosa	
6	6,7	3,1	4,7	1,5	versicolor	
7	5,7	3,8	1,7	0,3	setosa	
8	6,9	3,1	5,4	2,1	virginica	
9	6,1	2,8	4,7	1,2	versicolor	
10	6,3	3,3	6	2,5	virginica	
11	6,5	3	5,2	2	virginica	
12	5,9	3	5,1	1,8	virginica	
13	6,3	2,5	5	1,9	virginica	
14	6,9	3,1	4,9	1,5	versicolor	
15	5,4	2,7	1,5	0,2	setosa	

Figure 2.3: Iris-Datensatz


Scale	Operations	Description	Statistics	Example
Nominal	$=, \neq$	values have no natural order; they describe unordered categories	Mode (Modus)	München, Hamburg, Essen
Ordinal	$<, >$	values have a defined order; difference of values is undefined or has no clear or meaningful definition	Median	Schulnoten, Tabellenplatz in der Bundesliga
Interval	$+, -$	differences of values have the same meaning; adding provides useful results; zero point is not naturally/globally defined	Mean	Temperatur
Ratio	$\cdot, /$	zero point is naturally defined	(Generalized) Mean	Alter

Bemerkungen:

1. Skalenniveaus sind nicht immer klar zuzuordnen.
2. Auf nominalen Datenskalen lassen sich stets *künstliche Ordnungen* (und damit ordinale Datenskalen) definieren.
3. Bilden sie keine Mittelwerte auf Daten mit ordinalen Datenskalen!
4. Nominale und ordinale Datenskalen heißen auch *kategorisch* oder *qualitativ*.
5. Intervall und Ratio-Datenskalen heißen auch *metrisch*.

Ergänzend: Die fünf Skalenniveaus: Einfach und verständlich erklärt (statistikpsychologie.de)

2.4.2 Skalenniveaus im Iris-Datensatz



	A	B	C	D	E
1	sepal_len	sepal_wid	petal_len	petal_wid	class
2	7,2	3,6	6,1	2,5	virginica
3	5	3,6	1,4	0,2	setosa
4	4,4	3	1,3	0,2	setosa

Figure 2.4: Skalenniveaus bei Iris

Von Nominal zu Ordinal Wir werden später folgende eindeutige Zuordnung treffen:

Nominaler Wert	Ordinaler Wert
setosa	0
versicolor	1
virginica	2

Latex Part

Chapter 3

Chapter

3.1 Latex Section (H2)

Ich habe mich bemüht, zahlreiche Übungsbeispiele und Youtube-Videos einzubauen. Viele Themen lassen sich so besser darstellen. Sofern es Medien im Netz gibt,

Parskip!! die die Sachverhalte gut darstellen, werde ich entsprechenden Links einbauen. Der Autor muss ja nicht der Meinung sein, alles besser zu können. Gleichwohl darf dadurch der rote Faden nicht verl

3.1.1 Latex Subsection (H3)

Ich habe mich bemüht, zahlreiche Übungsbeispiele und Youtube-Videos einzubauen. Viele Themen lassen sich so besser darstellen. Sofern es Medien im Netz gibt, die die Sachverhalte gut darstellen, werde ich entsprechenden Links einbauen. Der Autor muss ja nicht der Meinung sein, alles besser zu können. Gleichwohl darf dadurch der rote Faden nicht verl

Latex SubSubSection (H4)

Ich habe mich bemüht, zahlreiche Übungsbeispiele und Youtube-Videos einzubauen. Viele Themen lassen sich so besser darstellen. Sofern es Medien im Netz gibt, die die Sachverhalte gut darstellen, werde ich entsprechenden Links einbauen. Der Autor muss ja nicht der Meinung sein, alles besser zu können. Gleichwohl darf dadurch der rote Faden nicht verl

Latex Paragraph (H5) Ich habe mich bemüht, zahlreiche Übungsbeispiele und Youtube-Videos einzubauen. Viele Themen lassen sich so besser darstellen. Sofern es Medien im Netz gibt, die die Sachverhalte gut darstellen, werde ich entsprechenden Links einbauen. Der Autor muss ja nicht der Meinung sein, alles besser zu können. Gleichwohl darf dadurch der rote Faden nicht verl